Circuito cerrado conversacional de voz (Voice AI)

Pre-entrega Módulo 6 · Proyecto integrador Torque Motopartes · Enzo Saporiti · Cohorte 2026

1. Evaluación de viabilidad: por qué incorporar voz a este proceso

Criterio	Evaluación para Torque Motopartes	Veredicto
Perfil del usuario	Motociclistas que consultan en movimiento, en el taller o con guantes: grabar un audio es más rápido que tipear.	Favorable
Tipo de consulta	Preguntas cortas y cerradas (plazos, costos, cuotas, garantías) con respuesta breve y verificable en el manual (RAG).	Favorable
Fatiga cognitiva	Respuestas largas por audio son difíciles de retener. Se mitiga con un máximo de 200 caracteres (unos 12 segundos de audio) y lenguaje para ser escuchado: sin listas, cifras dictadas, una idea por frase.	Controlada
Costo (ROI)	Transcripción con Groq Whisper (gratuita), voz con ElevenLabs (tope de 200 caracteres por respuesta, unas 50 respuestas por mes en el plan gratuito) y Claude Haiku (centavos). La contención financiera hace predecible el costo por consulta.	Favorable
Casos no aptos para voz	Consultas de pedidos con datos personales (número de pedido y email): por voz no se puede verificar la identidad. El agente deriva esos casos al canal escrito.	Excluidos por diseño

Arquitectura del circuito (tercer canal del Manager M6)

```
[Telegram Trigger] → [IF ¿Nota de voz ≤ 60 s?] — No → [Aviso: solo notas de voz]
      | Sí
      ▼
[Descargar audio] → [Normalizar formato .ogg] → [Whisper STT (Groq · es)] — Error → [Aviso técnico]
      ▼
[IF ¿Transcripción válida?] — No → [Aviso: no te entendí]
      | Sí
      ▼
[Texto limpio (audio descartado)] → [Agente Voz: Tools Agent + Claude Haiku + Vector Store Retrieve Tool (manual RAG)]
      ▼
[Contención 200 caracteres] → [ElevenLabs · Eleven Multilingual v2] — Error → [Fallback: respuesta en texto]
      ▼
[Telegram Send Audio] → [Payload log (sin binarios)] → [Slack: log canal voz]
```

2. Interceptación binaria de entrada y oídos del agente (Whisper)

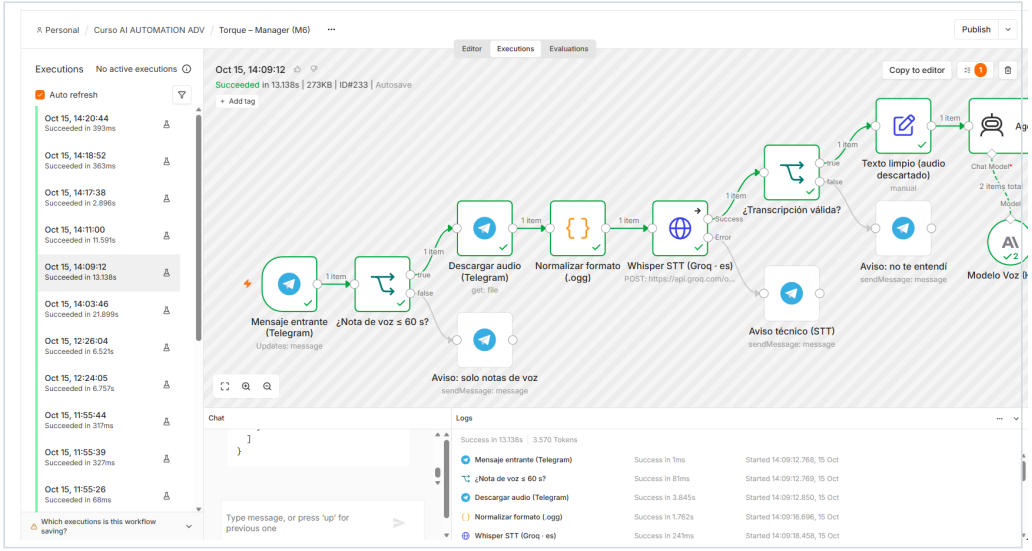


Figura 1. Ejecución #233: el bot oficial de Telegram recibe la nota de voz, el IF valida que sea audio de hasta 60 s, se descarga el binario, se normaliza a .ogg y se transcribe.

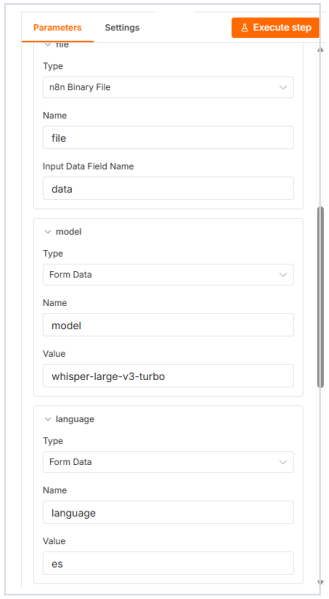


Figura 2. Nodo Whisper: binario data, modelo y language = es.

Trigger: bot oficial de Telegram (Telegram Trigger, actualizaciones de tipo `message`). El audio se descarga como binario solo si pasa el filtro de formato y duración.

Whisper (oídos del agente): modelo `whisper-large-v3-turbo` servido por Groq, mediante un endpoint compatible con la API de OpenAI y con plan gratuito. La **Input Binary Property** es `data` (campo `file`) y el **código de idioma** está fijado manualmente en `es`, lo que evita la autodetección y reduce la latencia: 201 a 241 ms por transcripción en las pruebas.

Normalización: Telegram entrega las notas de voz como `.oga`. Un nodo de 5 líneas solo renombra el archivo a `.ogg` (el mismo códec Opus) para que Whisper lo acepte.

Error de la API: la salida de error del nodo deriva a un aviso técnico al cliente, para que nunca quede sin respuesta.

3. Cerebro del sistema y contención financiera de 200 caracteres

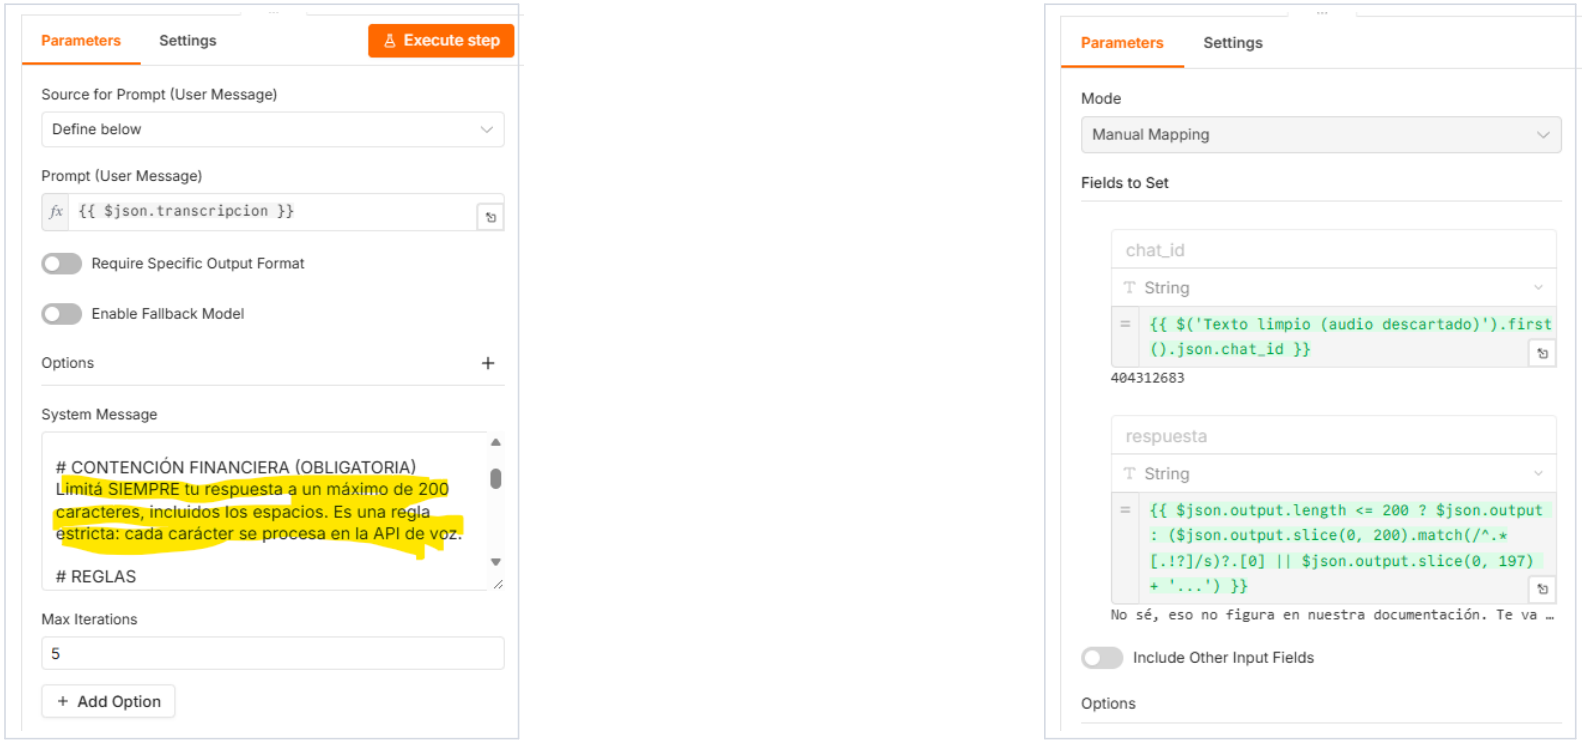
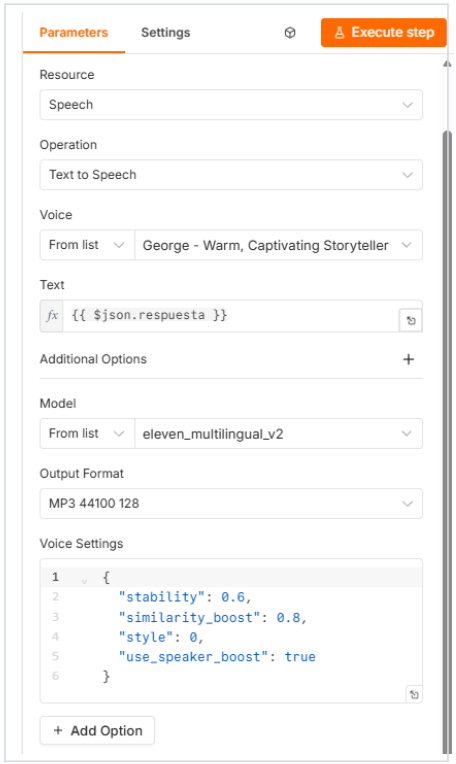


Figura 3. Agente Voz (Tools Agent) con la regla obligatoria de 200 caracteres en su System Message, y el nodo de contención que la refuerza.

AI Agent en modo Tools Agent: recibe directamente el texto limpio transcripto por Whisper (`{{ $json.transcripcion }}`). Tiene acoplada la herramienta **Vector Store Retrieve Tool** del Módulo 5, así que responde las políticas al 100% desde el manual y aplica la regla «No sé».

Contención financiera en dos capas: (1) el System Message ordena textualmente limitar *todas* las respuestas a un máximo de 200 caracteres; (2) el nodo «Contención 200 caracteres» corta el texto en el último punto antes del límite si el modelo se excede. Así, ElevenLabs nunca procesa más de 200 caracteres por respuesta. En las pruebas se enviaron 139 y 75 caracteres.

4. Voz del agente (ElevenLabs) y salida multimedia binaria



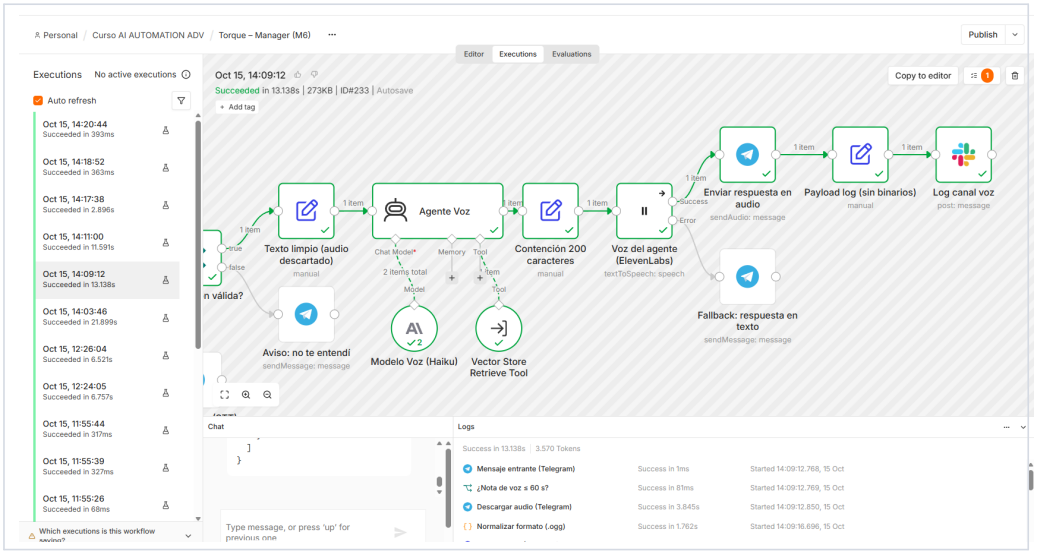


Figura 5. Ejecución #233: Contención → ElevenLabs (Success) → Telegram Send Audio → payload sin binarios → log en Slack.

Nodo nativo de ElevenLabs (nodo oficial verificado en n8n Cloud), operación Text to Speech:

- **Modelo:** `eleven_multilingual_v2`. Habla en español a partir del texto, sin código de idioma.
- **Stability:** 0,6, una voz estable y profesional, sin dramatismo, acorde a una marca de atención al cliente.
- **Similarity Boost (Clarity):** 0,8, una voz nítida y fiel. **Style:** 0. **Speaker boost:** activado.
- **Voz:** George, voz predeterminada de ElevenLabs. **Salida:** MP3 44,1 kHz.

Salida multimedia: el nodo de Telegram usa la operación **Send Audio** y toma dinámicamente el binario `data` generado por ElevenLabs.

Figura 4. Configuración del nodo ElevenLabs: voz, modelo, formato y Voice Settings.

5. Rutas de contingencia no-code

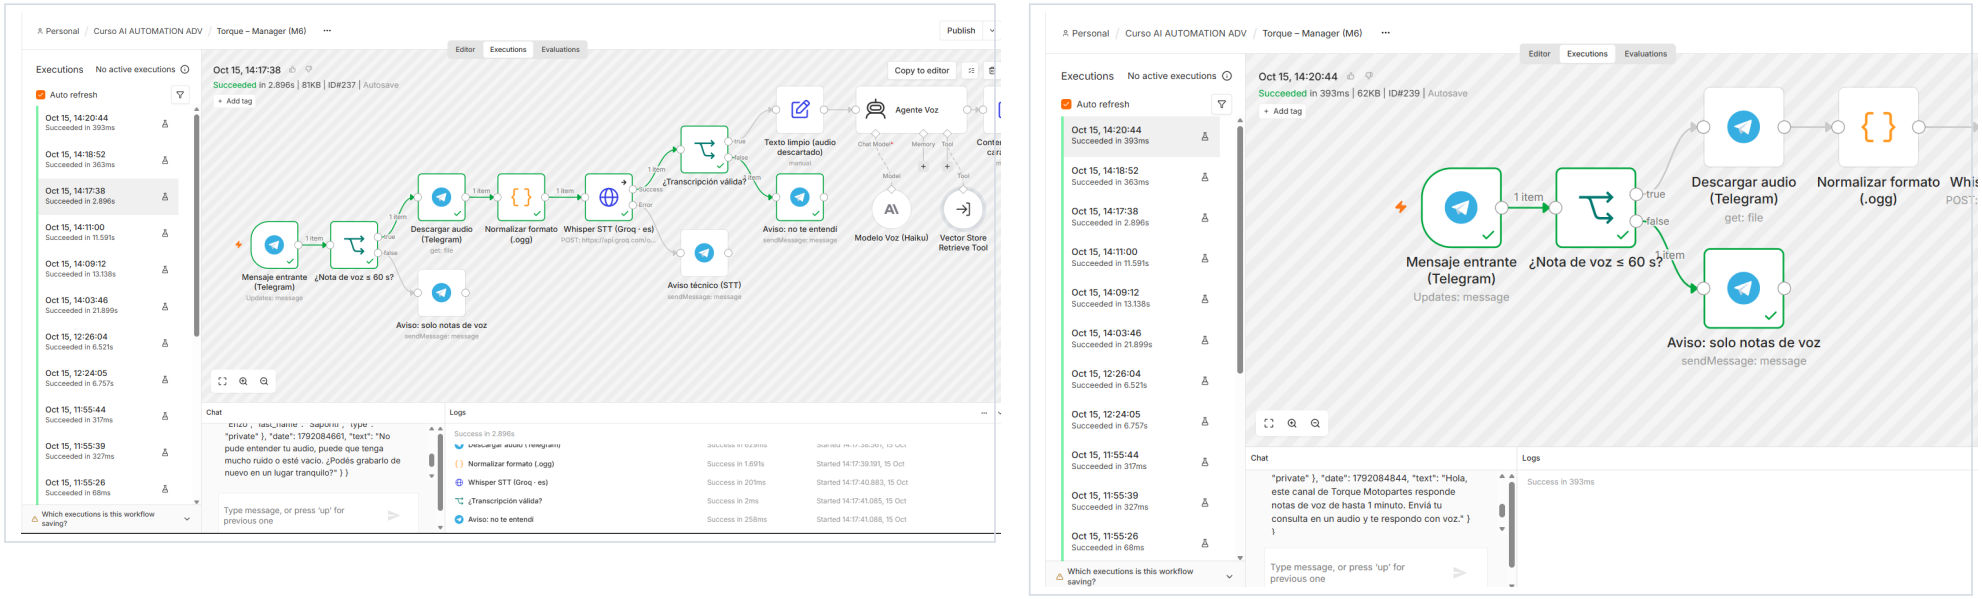


Figura 6. Izquierda: ejecución #237, audio sin voz útil desviado por el IF posterior a Whisper. Derecha: ejecución #239, audio de 66 s desviado antes de descargarse (sin costo).

Ruta	Condición	Respuesta al cliente	Evidencia
IF posterior a Whisper	Transcripción vacía o de menos de 5 caracteres (silencio, ruido extremo, audio corrupto)	«No pude entender tu audio... ¿Podés grabarlo de nuevo en un lugar tranquilo?»	Ejecución #237 ✓
IF de entrada	No es una nota de voz, o dura más de 60 s (protección de costo)	«Este canal responde notas de voz de hasta 1 minuto...»	Ejecuciones #238 (texto) y #239 (66 s) ✓
Error de Whisper	Falla o timeout de la API de transcripción	Aviso técnico y sugerencia de reintentar o escribir a soporte	Ruta configurada
Error de ElevenLabs	Falla de la API de voz	La misma respuesta del agente, enviada en texto (fallback)	Ejecución #227 ✓ (ver anexo)

6. Compliance y destrucción binaria

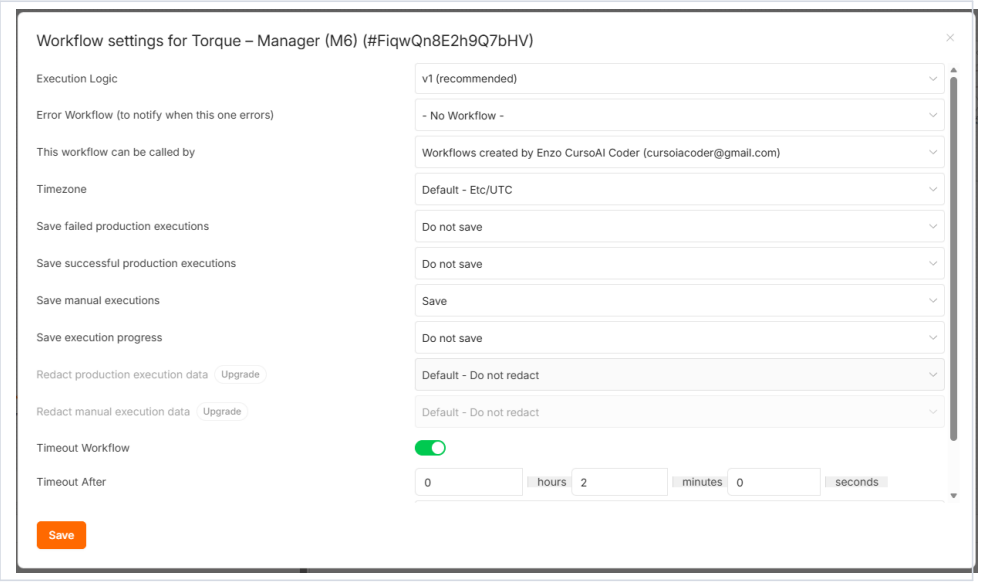


Figura 7. Configuración del Manager M6: las ejecuciones de producción no se guardan.

Procesamiento en memoria volátil: el audio del cliente existe solo dentro de la ejecución. Viaja desde la descarga hasta Whisper y se descarta en el nodo «Texto limpio (audio descartado)», a partir del cual solo circula texto.

Sin persistencia en producción: la configuración del workflow no guarda las ejecuciones de producción (ni exitosas ni fallidas) ni su progreso. Al terminar el flujo, los binarios de voz del cliente y de la respuesta se destruyen con la ejecución. Las ejecuciones manuales se conservan solo durante la fase de pruebas, para la evidencia de esta entrega.

Logs sin binarios: el nodo «Payload log (sin binarios)» envía a Slack únicamente texto: transcripción, respuesta, duración y caracteres. Nunca envía audio.

Minimización: por voz no se solicitan ni consultan datos personales ni pedidos; esos casos se derivan al canal escrito con verificación de identidad.

Credenciales: keys dedicadas al proyecto. La de ElevenLabs tiene un tope de 5.000 créditos y desactivación automática si se filtra (ver anexo).

7. Pruebas del circuito de punta a punta

#	Entrada	Recorrido	Resultado	Veredicto
1	Audio de 4 s: «Hola, ¿cuánto tarda un envío a Mendoza?»	Whisper → Agente + RAG → 139 caracteres → ElevenLabs → Send Audio	Audio: de 48 a 72 h hábiles desde la confirmación del pago; $7.900	✓ Ejec. #233
2	Audio de 3 s: «¿Me colocan la cadena si la compro?»	Whisper → Agente + RAG (sin resultados) → 75 caracteres → audio	Audio: «No sé, eso no figura en nuestra documentación. Te va a contactar un asesor.»	✓ Ejec. #235
3	Audio de 4 s sin voz útil	Whisper → IF de contingencia (rama false)	Texto: «No pude entender tu audio…»	✓ Ejec. #237
4	Mensaje de texto «Hola»	IF de entrada (rama false)	Texto: aviso de canal de notas de voz	✓ Ejec. #238
5	Audio de 66 s	IF de entrada (rama false), sin descargar ni transcribir	Texto: aviso de 1 minuto máximo (393 ms, costo cero)	✓ Ejec. #239

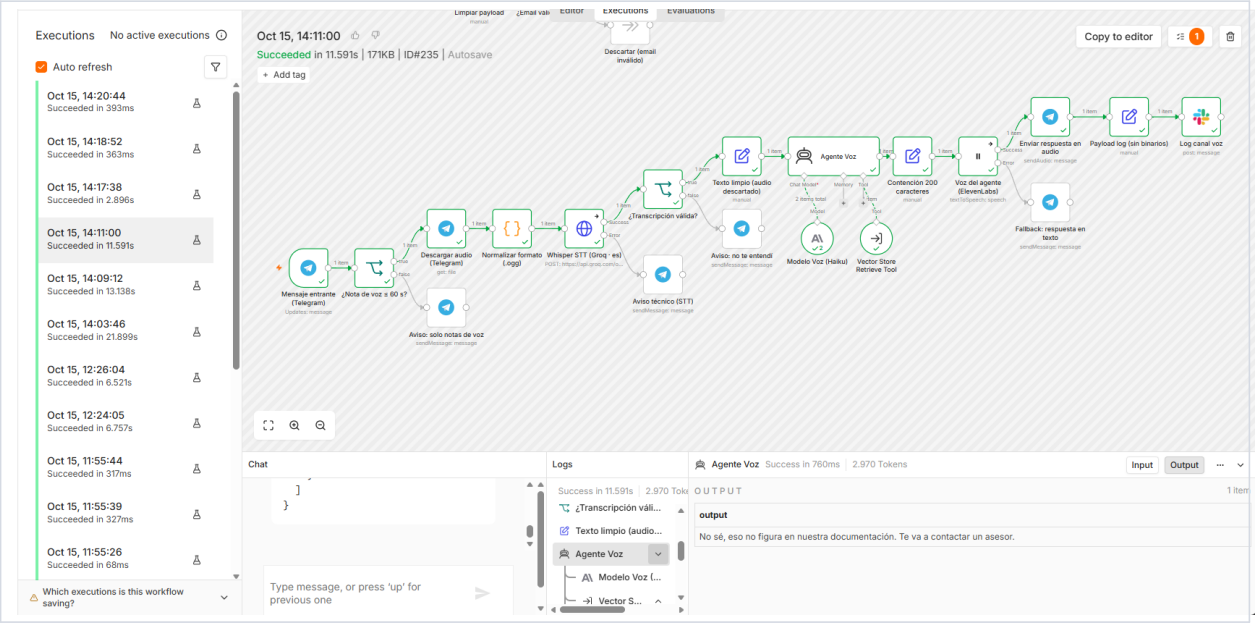


Figura 8. Ejecución #235 de punta a punta en verde, con respuesta en audio.

Anexos

Evidencia complementaria

A1 · Hallazgos y resiliencia · A2 · Fallback ante error de ElevenLabs · A3 · Conversación en Telegram
A4 · Logs del canal voz en Slack · A5 · API key de ElevenLabs

Anexo A1 · Hallazgos durante la implementación

Hallazgo	Causa	Resolución y aprendizaje
La herramienta RAG fallaba en la primera prueba	El vector store en memoria del Worker 3 se vació al reiniciarse la instancia de n8n. Es el riesgo previsto en el plan de gobernanza del Módulo 5.	Se reingestó el manual desde la rama manual (segundos, sin costo). Como el nodo de vector store no permite configurar una salida vacía, se incorpora al plan de gobernanza un control operativo: después de cada reinicio o despliegue de n8n, reingestar y repetir una pregunta de prueba. Mejora prevista: alerta automática en Slack cuando el Worker 3 no devuelva respuesta.
ElevenLabs rechazaba la solicitud (400 y luego 402 Payment required)	(1) La key restringida no permitía que el nodo validara la credencial ni listara voces. (2) La voz elegida era de la Voice Library, que el plan gratuito no permite usar por API.	Key dedicada con tope de créditos y desactivación automática si se filtra, y voz predeterminada (George). Mientras duró la falla, el **fallback de texto** garantizó que el cliente recibiera su respuesta (anexo A2).
Formato de audio de Telegram	Las notas de voz llegan como .oga.	Normalización a .ogg (mismo códec) antes de Whisper.

Anexo A2 · Fallback ante error de ElevenLabs

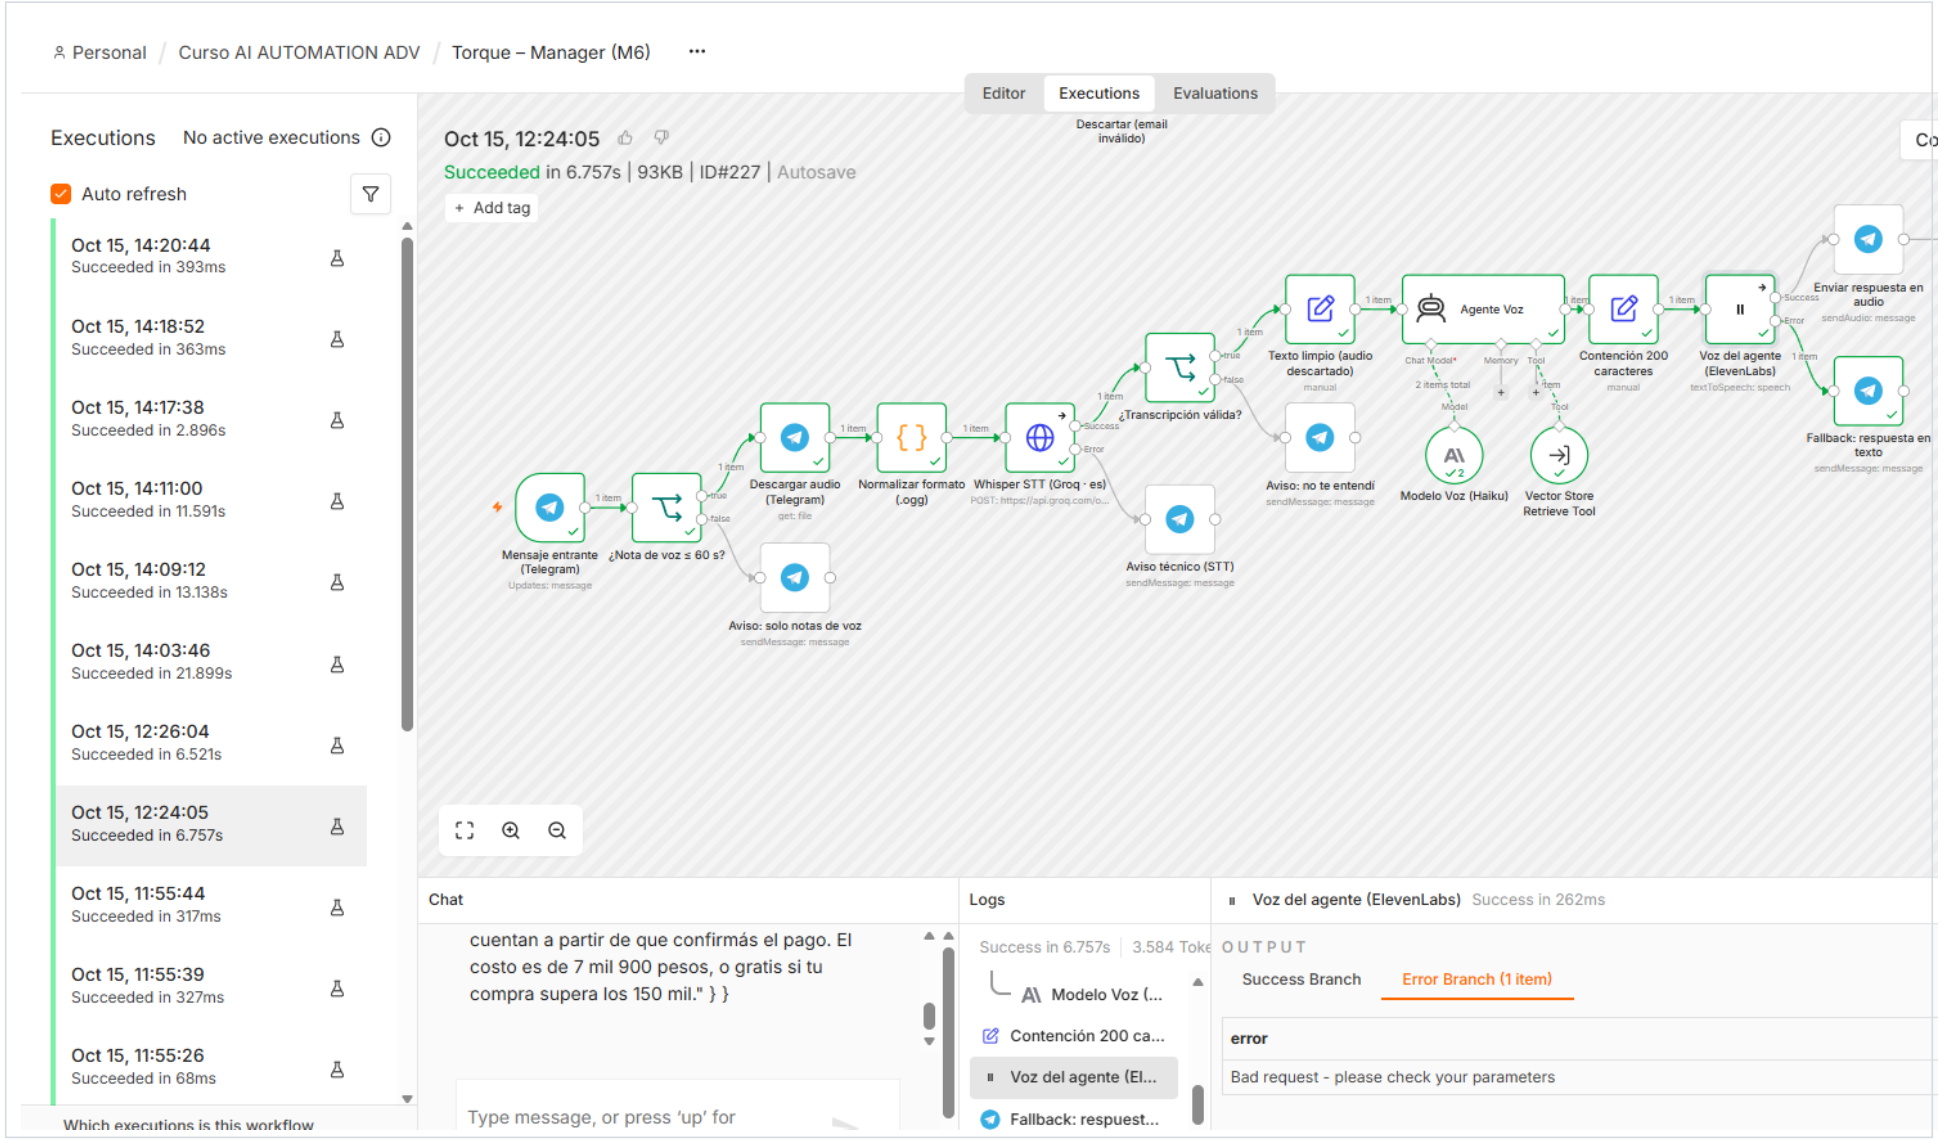


Figura A2. Ejecución #227: ElevenLabs devuelve error, la rama Error se activa y la respuesta del agente llega igual al cliente, en texto.

Anexo A3 y A4 · Conversación en Telegram y logs en Slack



Figura A3. Chat con el bot: respuestas en audio (pruebas 1 y 2) y avisos de contingencia (pruebas 3 y 4).

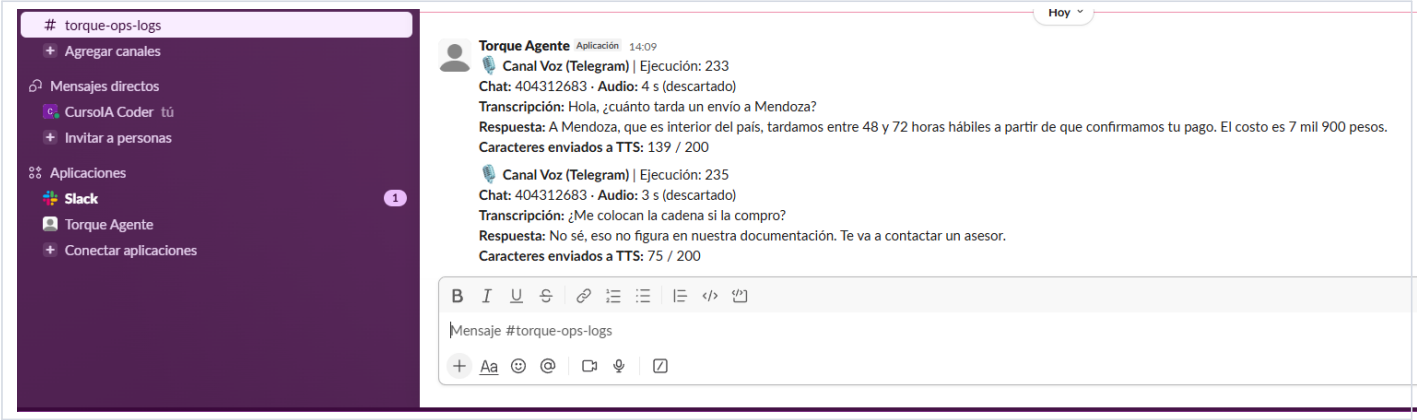


Figura A4. Log del canal voz: el audio se marca como descartado y se controlan los caracteres enviados a la API de voz.

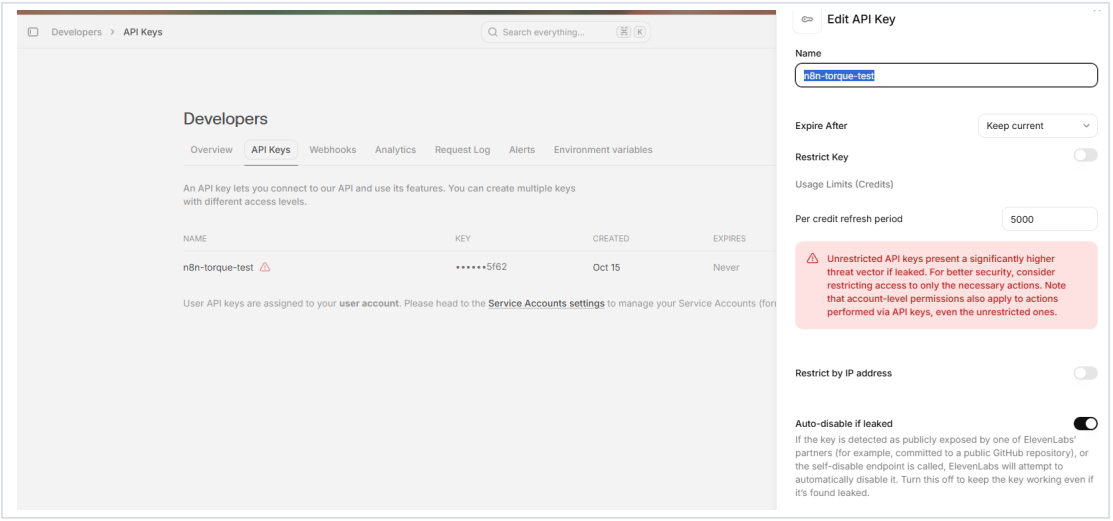


Figura A5. Key de ElevenLabs dedicada al proyecto: tope de 5.000 créditos por período y desactivación automática si se detecta una filtración.